뉴스 기사 분류: 다중 분류 문제

학습 내용

- 01 로이터 뉴스를 이용한 신경망 구현
- 02 다항분류 문제
 - 46개의 클래스로 구분(46개의 Topic를 예측하는 딥러닝 모델)

In [1]:

```
import keras
import numpy as np
keras.__version__
```

Out[1]:

'2.9.0'

로이터 뉴스를 46개의 상호 배타적인 토픽으로 분류하는 신경망

- 1986년에 로이터에서 공개한 짧은 뉴스 기사와 토픽의 집합인 로이터 데이터셋을 사용
- 46개의 토픽
- 각 토픽은 학습용 세트에 최소한 10개의 샘플
- 원본 Reuters Dataset : https://martin-thoma.com/nlp-reuters/ (https://martin-thoma.com/nlp-reuters/)
 - 90 classes, 7769 training document, 3019 test documents

46개의 토픽

['cocoa','grain','veg-oil','earn','acq','wheat','copper','housing','money-supply',
'coffee','sugar','trade','reserves','ship','cotton','carcass','crude','nat-gas', 'cpi','money-fx','interest','gnp','meal-feed','alum','oilseed','gold','tin', 'strategic-metal','livestock','retail','ipi','iron-steel','rubber','heat','jobs',
'lei','bop','zinc','orange','pet-chem','dlr','gas','silver','wpi','hog','lead']

데이터 가져오기

In [2]:

```
from keras.datasets import reuters

(train_data, train_labels), (test_data, test_labels) = reuters.load_data(num_words=10000)
```

• IMDB 데이터셋에서처럼 num_words=10000 매개변수는 데이터에서 가장 자주 등장하는 단어 10,000개로 제한

```
In [3]:
```

```
len(train_data), len(test_data), len(train_data)+ len(test_data)
```

Out[3]:

(8982, 2246, 11228)

In [4]:

```
# 46개의 토픽
print( np.unique(train_labels) )
```

[0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45]

In [5]:

```
# 11번째 데이터의 0~15 단어 확인
train_data[10][0:15]
```

Out [5]:

[1, 245, 273, 207, 156, 53, 74, 160, 26, 14, 46, 296, 26, 39, 74]

숫자로 변경되어 있는 것을 단어로 디코딩

In [6]:

```
print( "자료형 : ", type(reuters) )
print( "reuters의 기능 리스트 : ", dir(reuters) )
```

```
자료형: <class 'module'>
reuters의 기능 리스트: ['__builtins__', '__cached__', '__doc__', '__file__', '__lo
ader__', '__name__', '__package__', '__spec__', '_remove_long_seq', 'get_file', 'get
_word_index', 'json', 'keras_export', 'load_data', 'logging', 'np']
```

In [7]:

In [8]:

```
# 첫번째 뉴스 기사(숫자로 되어 있음)를 영문 매칭된 단어로 변경
decoded_newswire
```

Out[8]:

'??? said as a result of its december acquisition of space co it expects earnings per share in 1987 of 1 15 to 1 30 dlrs per share up from 70 cts in 1986 the company said pretax net should rise to nine to 10 mln dlrs from six mln dlrs in 1986 and ren tal operation revenues to 19 to 22 mln dlrs from 12 5 mln dlrs it said cash flow per share this year should be 2 50 to three dlrs reuter 3'

샘플과 연결된 레이블

• 토픽의 인덱스로 0과 45사이의 정수

In [9]:

```
train_labels[0:10]
```

Out [9]:

```
array([3, 4, 3, 4, 4, 4, 4, 3, 3, 16], dtype=int64)
```

데이터 준비

• 각각의 뉴스는 리스트로 이루어져 있음. 이를 딥러닝 모델에 맞추어 10000개의 차원으로 이루어진 벡터로 변환

In [10]:

```
import numpy as np

def vectorize_sequences(sequences, dimension=10000):
    results = np.zeros((len(sequences), dimension))
    for i, sequence in enumerate(sequences):
        results[i, sequence] = 1.
    return results

# 훈련 데이터 벡터 변환
X_train = vectorize_sequences(train_data)

# 테스트 데이터 벡터 변환
X_test = vectorize_sequences(test_data)

print("변환 전 : ", train_data.shape, test_data.shape)
print("변환 후 : ", X_train.shape, X_test.shape)
```

변환 전: (8982,) (2246,)

변환 후: (8982, 10000) (2246, 10000)

레이블(출력)을 벡터로 바꾸는 방법은 두 가지

- 레이블의 리스트를 정수 텐서로 변환하는 것
- 원-핫 인코딩을 사용하는 것

In [11]:

```
def to_one_hot(labels, dimension=46):
    results = np.zeros((len(labels), dimension))
    for i, label in enumerate(labels):
        results[i, label] = 1.
    return results

# 출력(레이블)을 벡터 변환(원핫)
# 훈련 레이블 벡터 변환
y_train = to_one_hot(train_labels)

# 테스트 레이블 벡터 변환
y_test = to_one_hot(test_labels)

print("변환 전: ", train_labels.shape, test_labels.shape)
print("변환 후: ", y_train.shape, y_test.shape)
```

변환 전 : (8982,) (2246,) 변환 후 : (8982, 46) (2246, 46)

• MNIST 예제에서 이미 보았듯이 케라스에는 이를 위한 내장 함수

모델 구성

- 마지막 출력이 46차원이기 때문에 중간층의 히든 유닛이 46개보다 많이 적어서는 안된다.
- 마지막 Dense 층의 크기가 46: 각 입력 샘플에 대해서 46차원의 벡터를 출력
- 마지막 층은 다항 분류의 경우, 활성화 함수로 softmax 활성화 함수을 사용
- 각 입력 샘플마다 46개의 출력 클래스에 대한 확률 분포를 출력
- 즉, 46차원의 출력 벡터를 만들며 output[i]는 어떤 샘플이 클래스 i에 속할 확률입니다. 46개의 값을 모두 더하면 1이 됩니다.
- 손실 함수는 categorical crossentropy
 - 이 함수는 두 확률 분포의 사이의 거리를 측정
 - 네트워크가 출력한 확률 분포와 진짜 레이블의 분포 사이의 거리
 - 두 분포 사이의 거리를 최소화하면 진짜 레이블에 가능한 가까운 출력을 내도록 모델을 훈련

실습해 보기

- (1) 가장 간단한 모델 구성
- (2) 모델 학습을 위한 학습, 검증용 데이터 셋을 나누어 학습 시켜보기

In [12]:

```
from keras import models
from keras import layers

model = models.Sequential()
model.add(layers.Dense(64, activation='relu', input_shape=(10000,)))
model.add(layers.Dense(64, activation='relu'))
model.add(layers.Dense(46, activation='softmax'))
```

In [13]:

모델 검증

• 훈련 데이터에서 8,892개에서 1,000개의 샘플을 따로 떼어서 검증 세트로 사용

In [14]:

```
X_val = X_train[:1000] # 0~8982 -> 0~1000개를 검증
partial_X_train = X_train[1000:] # 0~8982 -> 1000~끝까지 학습

y_val = y_train[:1000]
partial_y_train = y_train[1000:]
```

모델 학습

In [15]:

```
# 4. 모델 학습시키기
from keras.callbacks import EarlyStopping
early_stopping = EarlyStopping(patience = 20) # 조기종료 콜백함수 정의
```

In [16]:

```
Epoch 1/50
16/16 [========] - 1s 47ms/step - loss: 2.6023 - accuracy: 0.5
574 - val_loss: 1.7206 - val_accuracy: 0.6480
Epoch 2/50
                16/16 [======
055 - val_loss: 1.3046 - val_accuracy: 0.7120
Epoch 3/50
16/16 [========] - Os 23ms/step - Ioss: 1.0424 - accuracy: 0.7
704 - val_loss: 1.1329 - val_accuracy: 0.7510
16/16 [========] - Os 21ms/step - Ioss: 0.8264 - accuracy: 0.8
234 - val_loss: 1.0423 - val_accuracy: 0.7750
Epoch 5/50
16/16 [=============] - 0s 21ms/step - loss: 0.6590 - accuracy: 0.8
639 - val_loss: 0.9758 - val_accuracy: 0.7850
Epoch 6/50
                     =======] - Os 22ms/step - loss: 0.5278 - accuracy: 0.8
16/16 [========
924 - val_loss: 0.9325 - val_accuracy: 0.8010
Epoch 7/50
16/16 [=======] - Os 21ms/step - loss: 0.4212 - accuracy: 0.9
118 - val_loss: 0.9050 - val_accuracy: 0.8070
Epoch 8/50
16/16 [=============] - 0s 23ms/step - loss: 0.3406 - accuracy: 0.9
277 - val_loss: 0.9314 - val_accuracy: 0.8070
Epoch 9/50
16/16 [========] - Os 23ms/step - Ioss: 0.2822 - accuracy: 0.9
380 - val_loss: 0.8975 - val_accuracy: 0.8240
Epoch 10/50
16/16 [=======] - Os 24ms/step - Ioss: 0.2377 - accuracy: 0.9
465 - val_loss: 0.9213 - val_accuracy: 0.8160
Epoch 11/50
16/16 [=======] - Os 23ms/step - Ioss: 0.2045 - accuracy: 0.9
489 - val_loss: 0.9276 - val_accuracy: 0.8210
Epoch 12/50
16/16 [============] - 0s 22ms/step - loss: 0.1783 - accuracy: 0.9
540 - val_loss: 0.9470 - val_accuracy: 0.8090
Epoch 13/50
                    -----] - Os 21ms/step - Ioss: 0.1607 - accuracy: 0.9
16/16 [=======
524 - val_loss: 0.9839 - val_accuracy: 0.8060
Epoch 14/50
16/16 [========] - Os 21ms/step - Ioss: 0.1467 - accuracy: 0.9
549 - val_loss: 0.9593 - val_accuracy: 0.8120
Epoch 15/50
16/16 [=======] - Os 21ms/step - Ioss: 0.1410 - accuracy: 0.9
559 - val_loss: 1.0113 - val_accuracy: 0.8110
Epoch 16/50
16/16 [============] - 0s 21ms/step - loss: 0.1308 - accuracy: 0.9
557 - val_loss: 1.0080 - val_accuracy: 0.8060
Epoch 17/50
16/16 [=====
```

```
567 - val_loss: 1.0369 - val_accuracy: 0.8110
Epoch 18/50
16/16 [==========] - Os 22ms/step - loss: 0.1191 - accuracy: 0.9
585 - val_loss: 1.0722 - val_accuracy: 0.8170
Epoch 19/50
16/16 [=============] - 0s 21ms/step - loss: 0.1174 - accuracy: 0.9
555 - val_loss: 1.0933 - val_accuracy: 0.8050
Epoch 20/50
16/16 [=============] - 0s 21ms/step - loss: 0.1089 - accuracy: 0.9
592 - val_loss: 1.0903 - val_accuracy: 0.8010
Epoch 21/50
16/16 [=====
                           ======] - Os 23ms/step - loss: 0.1067 - accuracy: 0.9
588 - val_loss: 1.1132 - val_accuracy: 0.8050
Epoch 22/50
16/16 [========] - Os 22ms/step - Ioss: 0.1072 - accuracy: 0.9
564 - val_loss: 1.1302 - val_accuracy: 0.8010
Epoch 23/50
16/16 [=============] - 0s 21ms/step - loss: 0.1043 - accuracy: 0.9
598 - val_loss: 1.1421 - val_accuracy: 0.8090
Epoch 24/50
16/16 [========] - Os 21ms/step - Ioss: 0.1020 - accuracy: 0.9
579 - val_loss: 1.1808 - val_accuracy: 0.7940
Epoch 25/50
16/16 [========] - Os 21ms/step - Ioss: 0.1016 - accuracy: 0.9
579 - val_loss: 1.1543 - val_accuracy: 0.8030
Epoch 26/50
16/16 [========] - Os 21ms/step - Ioss: 0.0963 - accuracy: 0.9
577 - val_loss: 1.1646 - val_accuracy: 0.7920
Epoch 27/50
16/16 [=============] - 0s 23ms/step - loss: 0.0970 - accuracy: 0.9
585 - val_loss: 1.2086 - val_accuracy: 0.7980
Epoch 28/50
                       ======] - Os 22ms/step - loss: 0.0988 - accuracy: 0.9
16/16 [=====
609 - val_loss: 1.1898 - val_accuracy: 0.7930
Epoch 29/50
16/16 [==
                   =======] - Os 21ms/step - loss: 0.0942 - accuracy: 0.9
588 - val_loss: 1.2409 - val_accuracy: 0.7920
```

학습한 모델의 손실과 정확도 시각화

In [17]:


import matplotlib.pyplot as plt

In [18]:

```
loss = history.history['loss']
val_loss = history.history['val_loss']
epochs = range(1, len(loss) + 1)

plt.plot(epochs, loss, 'bo', label='Training loss')
plt.plot(epochs, val_loss, 'b', label='Validation loss')
plt.title('Training and validation loss')
plt.xlabel('Epochs')
plt.ylabel('Loss')
plt.legend()

plt.show()
```



In [19]:


```
plt.clf() # 그래프를 초기화합니다

acc = history.history['accuracy']

val_acc = history.history['val_accuracy']

plt.plot(epochs, acc, 'bo', label='Training acc')
plt.plot(epochs, val_acc, 'b', label='Validation acc')
plt.title('Training and validation accuracy')
plt.xlabel('Epochs')
plt.ylabel('Accuracy')
plt.legend()

plt.show()
```



모델 변경 - epochs을 변경

• 9번째 에포크 이후에 과대적합 시작. 9번의 에포크로 새로운 모델 훈련과 테스트 세트에서 평가

In [20]:

```
16/16 [========] - 2s 45ms/step - loss: 2.5403 - accuracy: 0.5
215 - val_loss: 1.6856 - val_accuracy: 0.6520
Epoch 2/9
16/16 [=============] - 1s 31ms/step - loss: 1.3841 - accuracy: 0.7
068 - val_loss: 1.2982 - val_accuracy: 0.7190
Epoch 3/9
16/16 [=============] - 0s 21ms/step - loss: 1.0358 - accuracy: 0.7
774 - val_loss: 1.1204 - val_accuracy: 0.7540
Epoch 4/9
16/16 [=============] - 0s 21ms/step - loss: 0.8171 - accuracy: 0.8
282 - val_loss: 1.0604 - val_accuracy: 0.7580
16/16 [=============] - 0s 23ms/step - loss: 0.6429 - accuracy: 0.8
671 - val_loss: 0.9618 - val_accuracy: 0.8100
Epoch 6/9
16/16 [=============] - 0s 22ms/step - loss: 0.5162 - accuracy: 0.8
961 - val_loss: 0.9130 - val_accuracy: 0.8150
Epoch 7/9
                     =======] - Os 21ms/step - loss: 0.4136 - accuracy: 0.9
16/16 [========
167 - val_loss: 0.9001 - val_accuracy: 0.8150
Epoch 8/9
16/16 [========] - 0s 23ms/step - loss: 0.3336 - accuracy: 0.9
303 - val_loss: 0.9443 - val_accuracy: 0.7950
Epoch 9/9
16/16 [========] - Os 20ms/step - Ioss: 0.2784 - accuracy: 0.9
376 - val_loss: 0.8945 - val_accuracy: 0.8140
71/71 [==============] - Os 2ms/step - loss: 0.9871 - accuracy: 0.78
50
```

In [21]:

```
results = model.evaluate(X_test, y_test)
print("최종 평가(loss, accuracy) : ", results)
```

```
71/71 [=========] - 0s 3ms/step - loss: 0.9871 - accuracy: 0.78 50
최종 평가(loss, accuracy) : [0.9871299266815186, 0.7849510312080383]
```

In [22]:

```
import copy

test_labels_copy = copy.copy(test_labels)

np.random.shuffle(test_labels_copy) # 데이터 섞기

float(np.sum(np.array(test_labels) == np.array(test_labels_copy))) / len(test_labels)
```

Out[22]:

0.19100623330365094

모델 학습 후, 테스트 데이터를 사용하여 예측

```
In [23]:
```

In [24]:

```
predictions[0].shape
```

Out [24]:

(46,)

In [25]:

```
# 마지막 예측 확률의 합은 1이 된다(softmax)
np.sum(predictions[0])
```

Out[25]:

0.999999

가장 큰 값이 예측 클래스가 된다.

```
In [26]:
```

```
# 확률이 가장 큰 값을 예측 클래스로 한다.
np.argmax(predictions[0])
```

Out [26]:

3

딥러닝 손실 함수

- 정수 레이블(타켓)을 그대로 사용할 때
- 손실함수를 sparse_categorical_crossentropy 를 사용

In [27]:

```
y_train = np.array(train_labels)
y_test = np.array(test_labels)
print(y_train.shape)
```

(8982,)

In [28]:

In [29]:

```
X_val = X_train[ :1000]
partial_x_train = X_train[1000:]

y_val = y_train[:1000]
partial_y_train = y_train[1000:]
```

In [30]:

```
partial_x_train.shape, partial_y_train.shape
```

Out [30]:

((7982, 10000), (7982,))

In [31]:

```
Epoch 1/20
16/16 [=======] - 1s 44ms/step - loss: 0.2605 - acc: 0.940
2 - val_loss: 0.8850 - val_acc: 0.8270
Epoch 2/20
16/16 [====
                      ========] - 1s 32ms/step - loss: 0.1956 - acc: 0.951
4 - val_loss: 0.9066 - val_acc: 0.8250
Epoch 3/20
16/16 [======] - Os 31ms/step - Ioss: 0.1721 - acc: 0.953
3 - val_loss: 0.9298 - val_acc: 0.8170
Epoch 4/20
16/16 [=======] - Os 23ms/step - Ioss: 0.1610 - acc: 0.954
5 - val_loss: 0.9962 - val_acc: 0.8020
Epoch 5/20
16/16 [=======] - 0s 22ms/step - loss: 0.1457 - acc: 0.954
6 - val_loss: 0.9331 - val_acc: 0.8220
Epoch 6/20
16/16 [============= ] - Os 21ms/step - Ioss: 0.1346 - acc: 0.956
7 - val_loss: 0.9964 - val_acc: 0.8100
Epoch 7/20
16/16 [======] - Os 20ms/step - Ioss: 0.1283 - acc: 0.956
0 - val_loss: 0.9602 - val_acc: 0.8200
Epoch 8/20
16/16 [============== ] - Os 20ms/step - Ioss: 0.1215 - acc: 0.957
0 - val_loss: 1.0062 - val_acc: 0.8130
Epoch 9/20
16/16 [======] - Os 20ms/step - Ioss: 0.1164 - acc: 0.956
2 - val_loss: 1.1222 - val_acc: 0.7810
Epoch 10/20
16/16 [=======] - Os 22ms/step - Ioss: 0.1131 - acc: 0.956
2 - val_loss: 1.0198 - val_acc: 0.8220
Epoch 11/20
16/16 [============ ] - Os 23ms/step - Ioss: 0.1112 - acc: 0.959
2 - val_loss: 1.0255 - val_acc: 0.8190
Epoch 12/20
16/16 [======] - Os 21ms/step - Ioss: 0.1063 - acc: 0.957
5 - val_loss: 1.0878 - val_acc: 0.8000
Epoch 13/20
16/16 [======] - Os 20ms/step - Ioss: 0.1061 - acc: 0.957
3 - val_loss: 1.1277 - val_acc: 0.7990
Epoch 14/20
16/16 [=======] - Os 20ms/step - Ioss: 0.1062 - acc: 0.956
7 - val_loss: 1.1222 - val_acc: 0.8110
Epoch 15/20
16/16 [========] - Os 20ms/step - loss: 0.1054 - acc: 0.959
3 - val_loss: 1.1368 - val_acc: 0.8000
Epoch 16/20
16/16 [============ ] - Os 23ms/step - Ioss: 0.0985 - acc: 0.957
3 - val_loss: 1.1511 - val_acc: 0.7970
Epoch 17/20
16/16 [=======] - Os 20ms/step - Ioss: 0.1019 - acc: 0.957
5 - val_loss: 1.1386 - val_acc: 0.8020
Epoch 18/20
```

In [32]:

```
results = model.evaluate(X_test, y_test)
print("최종 평가(loss, accuracy) : ", results)
```

```
71/71 [=======] - 0s 3ms/step - loss: 1.4533 - acc: 0.7711
최종 평가(loss, accuracy): [1.453325867652893, 0.771148681640625]
```

충분히 큰 중간층을 두기

• 출력층이 46차원이다. 중간층의 히든 유닛이 46개보다 적으면 안된다.

In [35]:

```
model = models.Sequential()
model.add(layers.Dense(64, activation='relu', input_shape=(10000,)))
model.add(layers.Dense(64, activation='relu'))
model.add(layers.Dense(46, activation='softmax'))
```

In [36]:

(7982, 10000) (7982,)

In [37]:

```
history = model.fit(partial_x_train, partial_y_train,
                 epochs=20,
                 batch_size=512,
                 validation_data=(X_val, y_val))
results = model.evaluate(X_test, y_test)
print("최종 평가(loss, accuracy) : ", results)
Epoch 1/20
16/16 [=======] - 1s 44ms/step - loss: 2.8246 - accuracy: 0.4
881 - val_loss: 1.8297 - val_accuracy: 0.6390
Epoch 2/20
                 -----] - 1s 34ms/step - loss: 1.4588 - accuracy: 0.7
16/16 [=======
021 - val_loss: 1.3205 - val_accuracy: 0.7160
Epoch 3/20
16/16 [========] - Os 27ms/step - loss: 1.0578 - accuracy: 0.7
726 - val_loss: 1.1440 - val_accuracy: 0.7540
Epoch 4/20
16/16 [========] - Os 20ms/step - Ioss: 0.8249 - accuracy: 0.8
229 - val_loss: 1.0533 - val_accuracy: 0.7610
Epoch 5/20
16/16 [=============] - 0s 25ms/step - loss: 0.6563 - accuracy: 0.8
641 - val_loss: 0.9833 - val_accuracy: 0.8050
Epoch 6/20
                      =======] - Os 22ms/step - loss: 0.5253 - accuracy: 0.8
16/16 [========
910 - val_loss: 0.9224 - val_accuracy: 0.8060
Epoch 7/20
16/16 [=======] - Os 20ms/step - loss: 0.4225 - accuracy: 0.9
136 - val_loss: 0.9075 - val_accuracy: 0.8080
Epoch 8/20
16/16 [=============] - Os 20ms/step - loss: 0.3425 - accuracy: 0.9
278 - val_loss: 0.9264 - val_accuracy: 0.8060
Epoch 9/20
16/16 [========] - Os 20ms/step - Ioss: 0.2834 - accuracy: 0.9
381 - val_loss: 0.9017 - val_accuracy: 0.8130
Epoch 10/20
16/16 [============] - 0s 21ms/step - loss: 0.2448 - accuracy: 0.9
441 - val_loss: 0.9313 - val_accuracy: 0.7970
Epoch 11/20
16/16 [=======] - Os 21ms/step - Ioss: 0.2095 - accuracy: 0.9
491 - val_loss: 0.9382 - val_accuracy: 0.8130
Epoch 12/20
16/16 [============] - Os 20ms/step - loss: 0.1829 - accuracy: 0.9
514 - val_loss: 0.9409 - val_accuracy: 0.8170
Epoch 13/20
                     ======] - Os 20ms/step - loss: 0.1686 - accuracy: 0.9
16/16 [========
528 - val_loss: 0.9551 - val_accuracy: 0.8080
Epoch 14/20
16/16 [========] - Os 20ms/step - Ioss: 0.1517 - accuracy: 0.9
536 - val_loss: 0.9960 - val_accuracy: 0.8080
Epoch 15/20
16/16 [=======] - Os 22ms/step - Ioss: 0.1417 - accuracy: 0.9
577 - val_loss: 0.9982 - val_accuracy: 0.8080
Epoch 16/20
16/16 [============] - 0s 23ms/step - loss: 0.1321 - accuracy: 0.9
565 - val_loss: 1.0284 - val_accuracy: 0.8110
Epoch 17/20
16/16 [=====
```

46차원보다 훨씬 작은 중간층(예를 들어 4차원)을 두면,

In [38]:

```
model = models.Sequential()
model.add(layers.Dense(64, activation='relu', input_shape=(10000,)))
model.add(layers.Dense(4, activation='relu'))
model.add(layers.Dense(46, activation='softmax'))
model.compile(optimizer='rmsprop',
            loss='sparse_categorical_crossentropy',
            metrics=['accuracy'])
history = model.fit(partial_x_train, partial_y_train,
                 epochs=20,
                 batch_size=512,
                 validation_data=(X_val, y_val))
results = model.evaluate(X_test, y_test)
print("최종 평가(loss, accuracy): ", results)
Epoch 1/20
16/16 [========] - 1s 42ms/step - loss: 3.3714 - accuracy: 0.1
708 - val_loss: 2.9908 - val_accuracy: 0.2350
Epoch 2/20
16/16 [=============] - 0s 31ms/step - loss: 2.7733 - accuracy: 0.2
532 - val_loss: 2.5808 - val_accuracy: 0.2650
Epoch 3/20
                       =======] - Os 25ms/step - Ioss: 2.3858 - accuracy: 0.2
16/16 [======
859 - val_loss: 2.2796 - val_accuracy: 0.2910
Epoch 4/20
16/16 [=======] - Os 23ms/step - Ioss: 2.0650 - accuracy: 0.3
061 - val_loss: 2.0128 - val_accuracy: 0.2990
Epoch 5/20
16/16 [==============] - Os 19ms/step - loss: 1.7698 - accuracy: 0.4
950 - val_loss: 1.7739 - val_accuracy: 0.6310
Epoch 6/20
16/16 [=======] - Os 19ms/step - loss: 1.5222 - accuracy: 0.6
478 - val_loss: 1.6131 - val_accuracy: 0.6360
Epoch 7/20
16/16 [============] - Os 20ms/step - loss: 1.3545 - accuracy: 0.6
512 - val_loss: 1.5124 - val_accuracy: 0.6330
Epoch 8/20
16/16 [=======] - Os 22ms/step - Ioss: 1.2402 - accuracy: 0.6
566 - val_loss: 1.4650 - val_accuracy: 0.6300
Epoch 9/20
16/16 [============] - 0s 21ms/step - loss: 1.1580 - accuracy: 0.6
668 - val_loss: 1.4289 - val_accuracy: 0.6400
Epoch 10/20
                      =======] - Os 19ms/step - Ioss: 1.0874 - accuracy: 0.6
16/16 [======
998 - val_loss: 1.4010 - val_accuracy: 0.6650
Epoch 11/20
16/16 [=========] - Os 19ms/step - loss: 1.0275 - accuracy: 0.7
184 - val_loss: 1.3720 - val_accuracy: 0.6730
Epoch 12/20
16/16 [=======] - Os 19ms/step - Ioss: 0.9725 - accuracy: 0.7
236 - val_loss: 1.3640 - val_accuracy: 0.6680
Epoch 13/20
16/16 [============] - 0s 21ms/step - loss: 0.9224 - accuracy: 0.7
253 - val_loss: 1.3627 - val_accuracy: 0.6740
Epoch 14/20
16/16 [=====
```

```
285 - val_loss: 1.3647 - val_accuracy: 0.6670
Epoch 15/20
               16/16 [======
329 - val_loss: 1.3609 - val_accuracy: 0.6830
Epoch 16/20
               16/16 [=====
626 - val_loss: 1.3840 - val_accuracy: 0.6870
Epoch 17/20
16/16 [===========] - Os 22ms/step - loss: 0.7526 - accuracy: 0.7
944 - val_loss: 1.3741 - val_accuracy: 0.7000
Epoch 18/20
16/16 [==
                        ======] - Os 23ms/step - loss: 0.7191 - accuracy: 0.8
120 - val_loss: 1.3965 - val_accuracy: 0.7090
Epoch 19/20
16/16 [==========] - Os 22ms/step - loss: 0.6852 - accuracy: 0.8
155 - val_loss: 1.3995 - val_accuracy: 0.7070
Epoch 20/20
16/16 [=============] - Os 18ms/step - Ioss: 0.6573 - accuracy: 0.8
206 - val_loss: 1.4305 - val_accuracy: 0.7030
71/71 [==================] - Os 2ms/step - loss: 1.5060 - accuracy: 0.68
최종 평가(loss, accuracy): [1.5060062408447266, 0.6865538954734802]
```

검증 정확도가 감소

- 검증 정확도의 약간 감소
- 추가 실험해보기
 - 더 크거나 작은 층을 사용해 보세요: 32개 유닛, 128개 유닛 등
 - 여기에서 두 개의 은닉층을 사용했습니다. 한 개의 은닉층이나 세 개의 은닉층을 사용해 보세요.

Summary

- 단일 레이블, 다중 분류 문제에서는 N개의 클래스에 대한 확률 분포를 출력하기 위해 softmax 활성화 함수를 사용
- 항상 범주형 크로스엔트로피를 사용
 - 이 함수는 모델이 출력한 확률 분포와 타깃 분포 사이의 거리를 최소화
- 다중 분류에서 레이블을 다루는 두가지 방법
 - 레이블을 범주형 인코딩(또는 원-핫 인코딩)으로 인코딩하고 categorical_crossentropy 손실 함수를 사용
 - 레이블을 정수로 인코딩하고 sparse categorical crossentropy 손실 함수를 사용