# 강아지 vs 고양이 분류하기(3)-VGG16

## 학습 내용

- 강아지와 고양이 데이터를 캐글로 부터 데이터를 준비
- 사전 훈련 모델에 대해 알아봅니다.
- VGG16 모델을 불러와 사용해 봅니다.
    - 데이터 증식을 사용하지 않은 작은 데이터 셋을 활용함.

# 데이터 이동

```
import os, shutil


### 드라이브 마운트
from google.colab import drive
drive.mount('/content/drive')
```

```
Mounted at /content/drive
```

```
!cp -r '/content/drive/My Drive/dataset/cats_dogs'  '/content/'
!ls -ls '/content/cats_dogs'
```

```
total 833956
    88 -rw------- 1 root root     88903 Nov 10 15:15 sampleSubmission.csv
277664 -rw------- 1 root root 284321224 Nov 10 15:15 test1.zip
556204 -rw------- 1 root root 569546721 Nov 10 15:15 train.zip
```

```
# 압축풀기
!rm -rf '/content/datasets/'
!unzip '/content/cats_dogs/test1.zip' -d '/content/datasets/'
!unzip '/content/cats_dogs/train.zip' -d '/content/datasets/'
```

```
!ls -ltr  '/content/datasets/' | head -10
!ls -ltr  '/content/datasets/train' | tail -10
!ls -ltr  '/content/datasets/test1' | tail -10
```

```
total 1044
drwxr-xr-x 2 root root 765952 Sep 20  2013 train
drwxr-xr-x 2 root root 299008 Sep 20  2013 test1
drwxr-xr-x 5 root root   4096 Nov 10 15:19 cats_and_dogs_small
-rw-r--r-- 1 root root 25671 Sep 20  2013 cat.9937.jpg
-rw-r--r-- 1 root root  3744 Sep 20  2013 cat.9936.jpg
-rw-r--r-- 1 root root 27700 Sep 20  2013 cat.9935.jpg
-rw-r--r-- 1 root root 32621 Sep 20  2013 cat.9999.jpg
-rw-r--r-- 1 root root  9937 Sep 20  2013 cat.9998.jpg
```

```
-rw-r--r-- 1 root root 18575 Sep 20  2013 cat.9997.jpg
-rw-r--r-- 1 root root 16855 Sep 20  2013 cat.9996.jpg
-rw-r--r-- 1 root root 13785 Sep 20  2013 cat.9995.jpg
-rw-r--r-- 1 root root 30029 Sep 20  2013 cat.9994.jpg
-rw-r--r-- 1 root root 29133 Sep 20  2013 cat.9993.jpg
-rw-r--r-- 1 root root  5286 Sep 20  2013 12440.jpg
-rw-r--r-- 1 root root 16612 Sep 20  2013 12439.jpg
-rw-r--r-- 1 root root 42306 Sep 20  2013 12438.jpg
-rw-r--r-- 1 root root 20759 Sep 20  2013 12437.jpg
-rw-r--r-- 1 root root 16850 Sep 20  2013 12436.jpg
-rw-r--r-- 1 root root 26283 Sep 20  2013 12435.jpg
-rw-r--r-- 1 root root 29062 Sep 20  2013 12434.jpg
-rw-r--r-- 1 root root 23917 Sep 20  2013 12500.jpg
-rw-r--r-- 1 root root 24012 Sep 20  2013 12499.jpg
-rw-r--r-- 1 root root 21471 Sep 20  2013 12498.jpg
```

```
!ls -al '/content/datasets/train' | head -5
!ls -l '/content/datasets/train' | grep ^- | wc -l
!ls -al '/content/datasets/test1' | head -5
!ls -l '/content/datasets/test1' | grep ^- | wc -l
```

```
total 609256
drwxr-xr-x 2 root root 765952 Sep 20  2013 .
drwxr-xr-x 4 root root   4096 Nov 10 15:18 ..
-rw-r--r-- 1 root root  12414 Sep 20  2013 cat.0.jpg
-rw-r--r-- 1 root root  21944 Sep 20  2013 cat.10000.jpg
25000
total 304288
drwxr-xr-x 2 root root 299008 Sep 20  2013 .
drwxr-xr-x 4 root root   4096 Nov 10 15:18 ..
-rw-r--r-- 1 root root  54902 Sep 20  2013 10000.jpg
-rw-r--r-- 1 root root  21671 Sep 20  2013 10001.jpg
12500
```

## 데이터 준비

- 데이터를 저장할 디렉터리 준비

```
# 원본 데이터셋을 압축 해제한 디렉터리 경로
ori_dataset_dir = './datasets/train'

# 소규모 데이터셋을 저장할 디렉터리
base_dir = './datasets/cats_and_dogs_small'


# 반복실행을 위해 디렉터리 삭제 ( cats_and_dogs_small )
if os.path.exists(base_dir):
    shutil.rmtree(base_dir)
os.mkdir(base_dir)


# 훈련, 검증, 테스트 분할을 위한 디렉터리
train_dir = os.path.join(base_dir, 'train')
os.mkdir(train_dir)

val_dir = os.path.join(base_dir, 'validation')
```

```
os.mkdir(val_dir)

test_dir = os.path.join(base_dir, 'test')
os.mkdir(test_dir)
```

```
  # 훈련용 고양이 사진 디렉터리
  train_cats_dir = os.path.join(train_dir, 'cats')
  os.mkdir(train_cats_dir)

  # 훈련용 강아지 사진 디렉터리
  train_dogs_dir = os.path.join(train_dir, 'dogs')
  os.mkdir(train_dogs_dir)

  # 검증용 고양이 사진 디렉터리
  val_cats_dir = os.path.join(val_dir, 'cats')
  os.mkdir(val_cats_dir)

  # 검증용 강아지 사진 디렉터리
  val_dogs_dir = os.path.join(val_dir, 'dogs')
  os.mkdir(val_dogs_dir)

  # 테스트용 고양이 사진 디렉터리
  test_cats_dir = os.path.join(test_dir, 'cats')
  os.mkdir(test_cats_dir)

  # 테스트용 강아지 사진 디렉터리
  test_dogs_dir = os.path.join(test_dir, 'dogs')
  os.mkdir(test_dogs_dir)
```

## 데이터를 복사

```
# 처음 1,000개의 고양이 이미지를 train_cats_dir에 복사합니다
fnames = ['cat.{}.jpg'.format(i) for i in range(1000)]
for fname in fnames:
    src = os.path.join(ori_dataset_dir, fname)
    dst = os.path.join(train_cats_dir, fname)
    shutil.copyfile(src, dst)

# 다음 500개 고양이 이미지를 validation_cats_dir에 복사합니다
fnames = ['cat.{}.jpg'.format(i) for i in range(1000, 1500)]
for fname in fnames:
    src = os.path.join(ori_dataset_dir, fname)
    dst = os.path.join(val_cats_dir, fname)
    shutil.copyfile(src, dst)

# 다음 500개 고양이 이미지를 test_cats_dir에 복사합니다
fnames = ['cat.{}.jpg'.format(i) for i in range(1500, 2000)]
for fname in fnames:
    src = os.path.join(ori_dataset_dir, fname)
    dst = os.path.join(test_cats_dir, fname)
    shutil.copyfile(src, dst)
```

```
# 처음 1,000개의 강아지 이미지를 train_dogs_dir에 복사합니다
fnames = ['dog.{}.jpg'.format(i) for i in range(1000)]
for fname in fnames:
    src = os.path.join(ori_dataset_dir, fname)
    dst = os.path.join(train_dogs_dir, fname)
    shutil.copyfile(src, dst)

# 다음 500개 강아지 이미지를 validation_dogs_dir에 복사합니다
fnames = ['dog.{}.jpg'.format(i) for i in range(1000, 1500)]
for fname in fnames:
    src = os.path.join(ori_dataset_dir, fname)
    dst = os.path.join(val_dogs_dir, fname)
    shutil.copyfile(src, dst)

# 다음 500개 강아지 이미지를 test_dogs_dir에 복사합니다
fnames = ['dog.{}.jpg'.format(i) for i in range(1500, 2000)]
for fname in fnames:
    src = os.path.join(ori_dataset_dir, fname)
    dst = os.path.join(test_dogs_dir, fname)
    shutil.copyfile(src, dst)

print('훈련용 고양이 이미지 전체 개수:', len(os.listdir(train_cats_dir)))
print('훈련용 강아지 이미지 전체 개수:', len(os.listdir(train_dogs_dir)))

print('검증용 고양이 이미지 전체 개수:', len(os.listdir(val_cats_dir)))
print('검증용 강아지 이미지 전체 개수:', len(os.listdir(val_dogs_dir)))

print('테스트용 고양이 이미지 전체 개수:', len(os.listdir(test_cats_dir)))
print('테스트용 강아지 이미지 전체 개수:', len(os.listdir(test_dogs_dir)))
```

```
훈련용 고양이 이미지 전체 개수: 1000
훈련용 강아지 이미지 전체 개수: 1000
검증용 고양이 이미지 전체 개수: 500
검증용 강아지 이미지 전체 개수: 500
테스트용 고양이 이미지 전체 개수: 500
테스트용 강아지 이미지 전체 개수: 500
```

## ▾ 사전 훈련된 컨브넷 사용.

- 작은 이미지 데이터 셋에 딥러닝을 적용하는 일반적이고 매우 효과적인 방법은 **사전 훈련된 네트워크를 사용**하는 것.
- 사전 훈련된 네트워크(pretrained network)는 일반적으로 대규모 이미지 분류 문제를 위해 대량의 데이터셋에서 미리 훈련되어 저장된 네트워크를 사용.

- ImageNet : 1400만개의 레이블된 이미지와 1000개의 클래스를 가진 데이터 셋.
- VGG16 : 캐런 시몬연(Keren Simonyan)과 앤드류 지서먼(Andrew Zisserman)이 2014년 개발
- 이외에도 VGG, ResNet, Inception, Inception-ResNet, Xception, MobileNet(2017), SeNet 등

사전 훈련된 네트워크를 사용하는 두가지 방법

- 특성 추출(feature extraction)
- 미세 조정((fine-tuning)

## 특성 추출

앞서 보았듯이 컨브넷은 이미지 분류를 위해 두 부분으로 구성됩니다.

- 연속된 **합성곱과 풀링 층**으로 시작
- **완전 연결 분류기(fully connected layer)**로 끝납니다.
    - 첫 번째 부분을 모델의 합성곱 기반층(convolutional base)이라고 함.
    - 컨브넷의 경우 특성 추출은 사전에 훈련된 네트워크의 합성곱 기반층을 선택해 새로운 데이터를 통과시키고 그 출력으로 새로운 분류기를 훈련

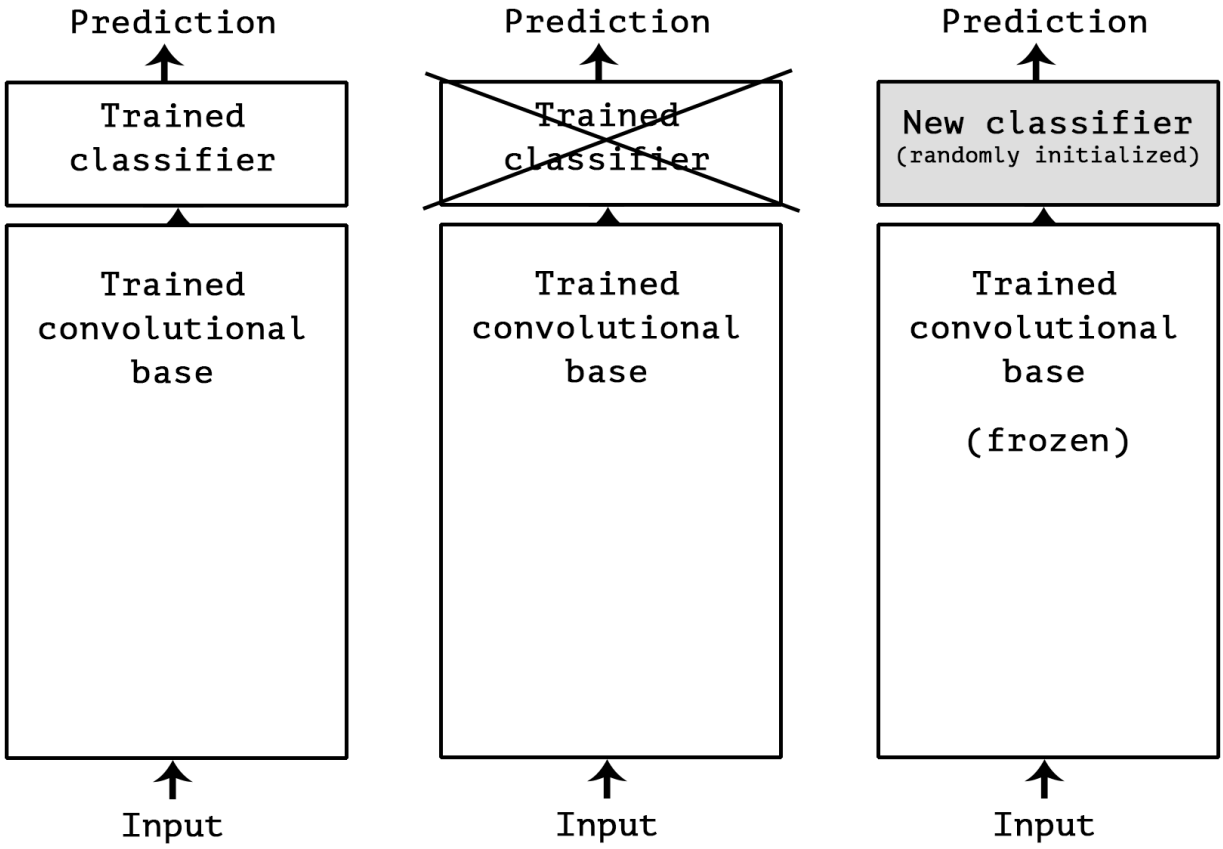


- 특정 합성곱 층에서 추출한 표현의 일반성(그리고 재사용성)의 수준은 모델에 있는 층의 깊이에 달려 있습니다.
    - 모델의 하위 층은 (에지, 색깔, 질감 등과 같이) **지역적이고 매우 일반적인 특성 맵을 추출**합니다.
    - 반면 **상위 층은 ('강아지 눈'이나 '고양이 귀'와 같이) 좀 더 추상적인 개념**을 추출

## 만약 새로운 데이터셋이 원본 모델이 훈련한 데이터셋과 많이 다를 경우,

- 전체 합성곱 기반층을 사용하는 것보다는 모델의 하위 층 몇 개만 특성 추출에 사용하는 것이 좋음.
- VGG16 모델은 케라스에 패키지로 포함되어 있습니다.
    - 현재 tensorflow.keras.applications 모듈에서 임포트 가능
    - tensorflow.keras.applications 모듈에서 사용 가능한 이미지 분류 모델은 다음과 같습니다(모두 ImageNet 데이터셋에서 훈련)

## CNN의 역사

- 2012년 : AlexNet - ILSVRC 우승 모델
- 2013년 : ZFNet - ILSVRC의 우승 모델
- 2014년 : GooLeNet – Going Deeper with Convolutions
    - 22개의 레이어를 사용한 더 Deep한 구조를 채용하여 ImageNet 2014에서 최고 성적
- 2014년 : VggNet - ImageNet Test(Top-5)에서 93.2%의 성공 2위 - 19개의 Conv filter를 사용
    - VGG16
    - VGG19
- 2015년 - ResNet – Deep Residual Learning for Image Recognition - 2015년 ILSVRC 우승
    - 152개의 Conv layer를 채용
    - ResNet50
- 2016년 - Xception
    - ImageNet test에서 79%(Top-1), 94.5%(Top-5)를 달성
- 2017년 - MobileNet
- InceptionV3
- 2017년 : DenseNet – Densely Connected Convolutional Networks
- 2019년 : EfficientNet – EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks
    - 84.4%(Top-1)을 달성

## 사전 훈련 네트워크 가져오기

```
from tensorflow.keras.applications import VGG16

conv_base = VGG16(weights='imagenet',
                  include_top=False,  # 완전 분류 연결기 포함/미포함
                  input_shape=(150, 150, 3))
```

```
Downloading data from https://storage.googleapis.com/tensorflow/keras-applications/vgg16/vgg1
58892288/58889256 [==============================] - 1s 0us/step
58900480/58889256 [==============================] - 1s 0us/step
```

- VGG16 함수에 세 개의 매개변수를 전달
  - weights는 모델을 초기화할 가중치 체크포인트를 지정
    - None, 'imagenet', weights의 path
  - include_top은 네트워크의 최상위 **완전 연결 분류기를 포함할지 안할지**를 지정.
    - 기본값은 ImageNet의 1,000개의 클래스에 대응되는 완전 연결 분류기를 포함.
    - 여기서는 별도의 (강아지와 고양이 두 개의 클래스를 구분하는) 완전 연결 층을 추가할 계획.
  - input_shape은 네트워크에 주입할 이미지 텐서의 크기입니다.
    - 이 매개변수는 선택사항입니다. 이 값을 지정하지 않으면 네트워크가 어떤 크기의 입력도 처리할 수 있습니다.

```
conv_base.summary()
```

```
Model: "vgg16"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_1 (InputLayer)         [(None, 150, 150, 3)]     0
_________________________________________________________________
block1_conv1 (Conv2D)        (None, 150, 150, 64)      1792
_________________________________________________________________
block1_conv2 (Conv2D)        (None, 150, 150, 64)      36928
_________________________________________________________________
block1_pool (MaxPooling2D)   (None, 75, 75, 64)        0
_________________________________________________________________
block2_conv1 (Conv2D)        (None, 75, 75, 128)       73856
_________________________________________________________________
block2_conv2 (Conv2D)        (None, 75, 75, 128)       147584
_________________________________________________________________
block2_pool (MaxPooling2D)   (None, 37, 37, 128)       0
_________________________________________________________________
block3_conv1 (Conv2D)        (None, 37, 37, 256)       295168
_________________________________________________________________
block3_conv2 (Conv2D)        (None, 37, 37, 256)       590080
_________________________________________________________________
block3_conv3 (Conv2D)        (None, 37, 37, 256)       590080
_________________________________________________________________
block3_pool (MaxPooling2D)   (None, 18, 18, 256)       0
_________________________________________________________________
block4_conv1 (Conv2D)        (None, 18, 18, 512)       1180160
_________________________________________________________________
block4_conv2 (Conv2D)        (None, 18, 18, 512)       2359808
_________________________________________________________________
block4_conv3 (Conv2D)        (None, 18, 18, 512)       2359808
_________________________________________________________________
block4_pool (MaxPooling2D)   (None, 9, 9, 512)         0
```

```
 block5_conv1 (Conv2D)       (None, 9, 9, 512)         2359808

 block5_conv2 (Conv2D)       (None, 9, 9, 512)         2359808

 block5_conv3 (Conv2D)       (None, 9, 9, 512)         2359808

 block5_pool (MaxPooling2D)  (None, 4, 4, 512)         0

=================================================================
Total params: 14,714,688
Trainable params: 14,714,688
Non-trainable params: 0
_________________________________________________________________
```

- VGG16은 합성곱 13개, 완전 연결 층(FCL) 3개.
    - include_top이 기본값이 True일 경우 input_shape이 원본 모델과 동일한 (224, 224, 3)이 되어야 한다.
- 다른 모델 VGG19는 합성곱 층 16개, 완전 연결 층 3개로 이루어져 있음.

## 실습 : 데이터 증식을 사용하지 않는 빠른 특성 추출

```
import os
import numpy as np
from keras.preprocessing.image import ImageDataGenerator

# 소규모 데이터셋을 저장할 디렉터리
base_dir = './datasets/cats_and_dogs_small'

# 데이터 디렉터리
train_dir = os.path.join(base_dir, 'train')
validation_dir = os.path.join(base_dir, 'validation')
test_dir = os.path.join(base_dir, 'test')

datagen = ImageDataGenerator(rescale=1./255)
batch_size = 20
```

## 이미지 제너레이터를 활용한 데이터 가져오기

```
def extract_features(directory, sample_count):
    features = np.zeros(shape=(sample_count, 4, 4, 512))
    labels = np.zeros(shape=(sample_count))

    print("피처, 레이블 : ", features.shape, labels.shape  )

    generator = datagen.flow_from_directory(
        directory,
        target_size=(150, 150),
        batch_size=batch_size,
```

```
        class_mode='binary')

    i = 0
    for inputs_batch, labels_batch in generator:
        features_batch = conv_base.predict(inputs_batch)
        #print(  type(features_batch), features_batch.shape  )
        features[i * batch_size : (i + 1) * batch_size] = features_batch
        labels[i * batch_size : (i + 1) * batch_size] = labels_batch
        i += 1
        if i * batch_size >= sample_count:
            # 제너레이터는 루프 안에서 무한하게 데이터를 만들어내므로
            # 모든 이미지를 한 번씩 처리하고 나면 중지합니다
            break
    #print(  type(features), features_batch.shape  )
    return features, labels


t_features, t_labels = extract_features(train_dir, 100)
print( t_features.shape, t_labels.shape )
```

```
피처, 레이블 :  (100, 4, 4, 512) (100,)
Found 2000 images belonging to 2 classes.
<class 'numpy.ndarray'> (20, 4, 4, 512)
<class 'numpy.ndarray'> (20, 4, 4, 512)
<class 'numpy.ndarray'> (20, 4, 4, 512)
<class 'numpy.ndarray'> (20, 4, 4, 512)
<class 'numpy.ndarray'> (20, 4, 4, 512)
<class 'numpy.ndarray'> (20, 4, 4, 512)
(100, 4, 4, 512) (100,)
```

```
%%time

train_features, train_labels = extract_features(train_dir, 2000)
validation_features, validation_labels = extract_features(validation_dir, 1000)
test_features, test_labels = extract_features(test_dir, 1000)
```

```
피처, 레이블 :  (2000, 4, 4, 512) (2000,)
Found 2000 images belonging to 2 classes.
피처, 레이블 :  (1000, 4, 4, 512) (1000,)
Found 1000 images belonging to 2 classes.
피처, 레이블 :  (1000, 4, 4, 512) (1000,)
Found 1000 images belonging to 2 classes.
```

```
print( train_features.shape, train_labels.shape )
print( validation_features.shape, validation_labels.shape )
print( test_features.shape, test_labels.shape )
```

```
(2000, 4, 4, 512) (2000,)
(1000, 4, 4, 512) (1000,)
(1000, 4, 4, 512) (1000,)
```

- 추출된 특성(데이터)의 크기는 (samples, 4, 4, 512). 완전 연결 분류기에 주입하기 위해 먼저 (samples, 8192)크기로 펼치기

```
train_features = np.reshape(train_features, (2000, 4 * 4 * 512))
validation_features = np.reshape(validation_features, (1000, 4 * 4 * 512))
test_features = np.reshape(test_features, (1000, 4 * 4 * 512))
```

## 완전 연결 분류기 정의(FCL)

- 완전 연결 분류기(FCL)를 정의
- 신경망의 규제를 위해 드롭아웃을 사용.
- 저장된 데이터와 레이블을 사용해 훈련

```
from tensorflow.keras import models
from tensorflow.keras import layers
from tensorflow.keras import optimizers
```

```
%%time

# 완전 연결층
model = models.Sequential()
model.add(layers.Dense(256, activation='relu', input_dim=4 * 4 * 512))
model.add(layers.Dropout(0.5))
model.add(layers.Dense(1, activation='sigmoid'))

model.compile(optimizer=optimizers.RMSprop(lr=2e-5),
              loss='binary_crossentropy',
              metrics=['acc'])

history = model.fit(train_features, train_labels,
                    epochs=30,
                    batch_size=20,
                    validation_data=(validation_features, validation_labels))
```

```
Epoch 4/30
100/100 [==============================] - 2s 23ms/step - loss: 0.3201 - acc: 0.8735 - v
Epoch 5/30
100/100 [==============================] - 2s 24ms/step - loss: 0.2906 - acc: 0.8885 - v
Epoch 6/30
100/100 [==============================] - 2s 25ms/step - loss: 0.2690 - acc: 0.8880 - v
Epoch 7/30
100/100 [==============================] - 2s 24ms/step - loss: 0.2488 - acc: 0.8970 - v
Epoch 8/30
100/100 [==============================] - 2s 24ms/step - loss: 0.2371 - acc: 0.9120 - v
Epoch 9/30
100/100 [==============================] - 2s 24ms/step - loss: 0.2219 - acc: 0.9150 - v
Epoch 10/30
100/100 [==============================] - 2s 24ms/step - loss: 0.2145 - acc: 0.9155 - v

Epoch 11/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1954 - acc: 0.9280 - v
Epoch 12/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1834 - acc: 0.9365 - v
Epoch 13/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1803 - acc: 0.9365 - v
Epoch 14/30
100/100 [==============================] - 2s 25ms/step - loss: 0.1758 - acc: 0.9355 - v
```

```
Epoch 15/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1674 - acc: 0.9425 - v
Epoch 16/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1639 - acc: 0.9435 - v
Epoch 17/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1516 - acc: 0.9505 - v
Epoch 18/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1509 - acc: 0.9420 - v
Epoch 19/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1426 - acc: 0.9540 - v
Epoch 20/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1374 - acc: 0.9515 - v
Epoch 21/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1284 - acc: 0.9585 - v
Epoch 22/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1239 - acc: 0.9550 - v
Epoch 23/30
100/100 [==============================] - 2s 25ms/step - loss: 0.1218 - acc: 0.9575 - v
Epoch 24/30
100/100 [==============================] - 3s 25ms/step - loss: 0.1143 - acc: 0.9615 - v
Epoch 25/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1111 - acc: 0.9610 - v
Epoch 26/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1110 - acc: 0.9675 - v
Epoch 27/30
100/100 [==============================] - 2s 23ms/step - loss: 0.0981 - acc: 0.9705 - v
Epoch 28/30
100/100 [==============================] - 2s 24ms/step - loss: 0.1051 - acc: 0.9670 - v
Epoch 29/30
100/100 [==============================] - 2s 24ms/step - loss: 0.0960 - acc: 0.9695 - v
Epoch 30/30
100/100 [==============================] - 2s 24ms/step - loss: 0.0919 - acc: 0.9730 - v
CPU times: user 1min 58s, sys: 4.39 s, total: 2min 2s
Wall time: 1min 12s
```

- FCL(완전 연결층)2개의 Dense 층만 처리하면 되기 때문에 훈련이 빠르다.
    - 합성곱 층의 가중치는 사전 훈련 네트워크 가중치 이용.
    - 데이터가 늘어날 경우 정확도가 올라간다.

## 훈련 손실과 정확도 곡선

```
import matplotlib.pyplot as plt

acc = history.history['acc']
val_acc = history.history['val_acc']
loss = history.history['loss']
val_loss = history.history['val_loss']

epochs = range(len(acc))

plt.plot(epochs, acc, 'bo', label='Training acc')
plt.plot(epochs, val_acc, 'b', label='Validation acc')
```

```
plt.title('Training and validation accuracy')
plt.legend()

plt.figure()

plt.plot(epochs, loss, 'bo', label='Training loss')
plt.plot(epochs, val_loss, 'b', label='Validation loss')
plt.title('Training and validation loss')
plt.legend()

plt.show()
```

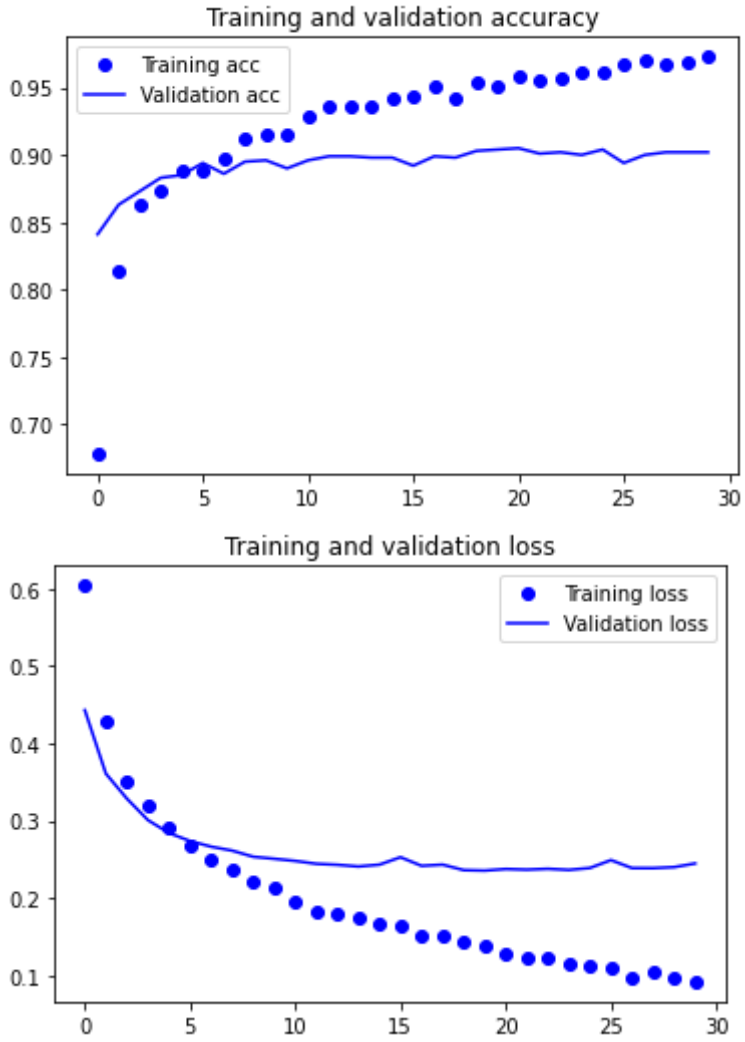


## Summary

- validation 90%의 검증 정확도에 도달
- 앞에서 처음부터 훈련시킨 작은 모델에서 얻은 것보다 훨씬 좋음.
- 드롭아웃을 사용했음에도 불구하고 훈련이 시작하면서 거의 바로 과대적합되고 있다는 것
    - 과대적합의 이유 **작은 이미지 데이터셋**에서는 과대적합을 막기 위해 필수적인 데이터 증식을 사용하지 않음.

## REFERENCE

- keras applications : https://keras.io/api/applications/
- CNN의 이야기
    - https://engineer-mole.tistory.com/43
    - https://junklee.tistory.com/111